

# Архитектура системы

Мультиагентная система представляет собой набор специализированных агентов, которые совместно решают задачу глубокого анализа темы и поиска источников. Система следует модели «Менеджер → агенты-исполнители». Это означает, что **центральный агент - координатор (Менеджер)** управляет процессом: распределяет задачи между вспомогательными агентами, принимает и объединяет их результаты. Такой подход обеспечивает модульность и масштабируемость: каждый агент сфокусирован на узкой функции, а Менеджер обеспечивает взаимодействие.

Основные компоненты архитектуры могут быть следующими:

- **Агент-планировщик (Planner Agent):** генерирует первоначальный план поиска по теме. Анализирует входной запрос, разбивает его на подтемы и ключевые понятия. Эта роль подтверждается практикой создания «агентов-планировщиков» в сложных системах. Планировщик определяет цели поиска (какие данные нужны, какие вопросы следует осветить) и передаёт задачи другим агентам.
- **Агент уточнения запроса (Query Refinement Agent):** на основе промежуточных результатов пересматривает и формулирует запросы заново. При необходимости агрегирует новые термины (с помощью синонимов, уточнений), исключает нерелевантные слова. Такой итеративный подход к уточнению запросов улучшает качество поиска : например, при поиске в систематических обзорах показано, что уточнение Boolean-запросов увеличивает точность без потери полноты.
- **Агенты поиска и извлечения (Retrieval/Search Agents):** выполняют поиск релевантных источников в разных хранилищах. Это могут быть несколько агентов: один работает с академическими базами (PubMed, IEEE, arXiv и др.), другой – с веб-ресурсами или общедоступными API. Каждый из них специализируется на конкретном типе данных и использует подходящие методы (ключевые слова, фильтры). Наличие множества поисковых агентов обеспечивает более широкий охват информации и отказоустойчивость. Эти агенты классифицируются как «агенты-ретриверы».
- **Аналитический агент (Analysis/Summarization Agent):** обрабатывает найденные документы, извлекает основные идеи и формирует «цепочку рассуждений». Он резюмирует содержание источников, устанавливает связи между ними и ключевыми понятиями темы. Такой агент выполняет задачи свёртки информации и рассуждений (reasoning) , обеспечивая понимание контекста. Он же может подготавливать промежуточные выводы для планировщика (например, сообщать об обнаруженных фактах для уточнения следующих запросов).
- **Агент контроля качества (Evaluation Agent):** непрерывно оценивает работу других агентов (см. ниже раздел «Методы оценки»). Он следит за тем, достигнуты ли цели поиска, не дублируются ли запросы, и решает, когда останавливать итерации. Например, может сравнивать количество новых релевантных источников по сравнению с предыдущей итерацией.

- **Интерфейсный агент (User Interface Agent):** обеспечивает взаимодействие с пользователем. Получает исходный запрос, передаёт готовые результаты (список источников и рассуждений), собирает обратную связь (например, оценку релевантности) и может передавать её Менеджеру.

В совокупности такая архитектура соответствует практике распределения обязанностей между задачей-ориентированными агентами: **агенты-специалисты** (retrieval, summarization, reasoning) выполняют узкие функции, а **координирующий агент** (Менеджер) управляет их взаимодействием. Система может быть спроектирована по паттерну «Supervisor» (все агенты общаются через Менеджер) или **иерархически**, когда есть несколько уровней руководства.

## Сценарий взаимодействия агентов при выполнении задачи

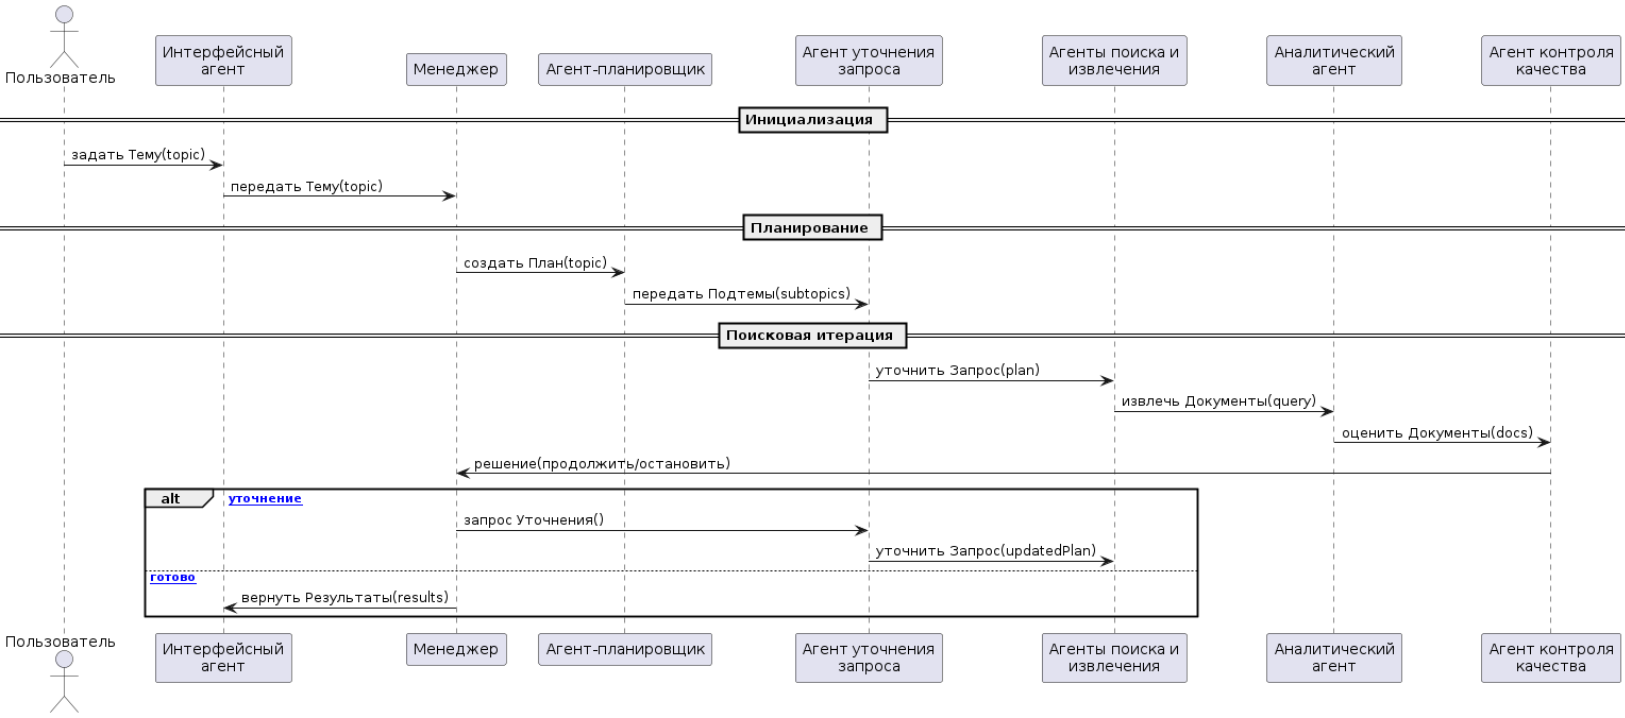
1. **Поступление запроса:** Пользователь формулирует исследовательскую тему и передаёт её системе. Запрос поступает в Менеджер.
2. **Планирование поиска:** Менеджер запускает Агент-планировщик, который анализирует тему и строит пошаговый план исследования. Планировщик определяет список подтем и ключевых вопросов (например, определяет, какие аспекты темы требуют поиска).
3. **Первый раунд поиска:** На основе плана формируется исходная поисковая формулировка. Менеджер направляет задачу Агента поиска. Один или несколько поисковых агентов обращаются к внешним источникам (научным базам, интернет-ресурсам) и извлекают первые релевантные документы.
4. **Анализ результатов:** Найденные документы передаются Аналитическому агенту. Он обрабатывает их: извлекает ключевые тезисы, метаданные (авторы, год), строит сеть понятий. На этом этапе может выполняться первоначальный отбор: отсеивание нерелевантных результатов.
5. **Уточнение запроса:** Если анализа оказалось недостаточно (например, найдены лишь общие сведения, или результаты слишком размыты), Менеджер активирует Агент уточнения запроса. Этот агент на основе промежуточных выводов планировщика и анализа переформулирует поисковый запрос, вводя дополнительные уточняющие термины или убирая шумовые слова.
6. **Новый раунд поиска:** Обновлённый запрос передаётся поисковым агентам для повторного поиска. Этот цикл (поиск – анализ – уточнение) повторяется, пока не будет достигнут критерий остановки: например, появление большого числа повторяющихся источников, отсутствие новых релевантных документов или исчерпание допустимого числа итераций.
7. **Формирование ответа:** После завершения итераций Менеджер собирает окончательный набор релевантных источников и выводов аналитического агента. Затем комплексно формируется ответ пользователю: список с описаниями найденных статей и цепочка рассуждений (например, логическая последовательность аргументов и ссылок на источники).

8. **Обратная связь:** Пользователь может оценить полезность найденных результатов. Интерфейсный агент получает эту обратную связь и передаёт Менеджеру для возможной донастройки (например, при переформулировке будущих запросов).

Таким образом агенты работают по очереди и в итеративной схеме: Менеджер управляет «handoff» между этапами (план → поиск → анализ → уточнение). Отдельные агенты могут работать параллельно (например, несколько поисковых агентов обходят разные базы), но их результаты всё равно консолидируются Менеджером.



Рис. 1 – Диаграмма основных взаимодействий агентов



## Методы оценки качества работы

Для оценки качества работы системы и каждого агента применяются стандартные и специальные метрики:

- **Точность и полнота поиска (Precision, Recall):** измеряют качество retrieval-агентов. Precision (точность) показывает долю реально релевантных документов в выданных, а Recall (полнота) – долю найденных релевантных документов относительно всех существующих релевантных. Общие показатели (например, Precision@K, Recall@K, MAP, NDCG) широко используются в информационном поиске.
- **Полнота планирования:** для Агентов планирования и уточнения важно измерять, насколько полно покрыта исследуемая тема. Это может оцениваться как доля ключевых подтем, охваченных поисковыми запросами (эту метрику можно ввести на основании контрольного списка релевантных понятий, составленного экспертом или с помощью базы знаний).
- **Корректность уточнения запросов:** здесь оценивается, насколько изменения запроса действительно улучшают результаты. Можно сравнивать Precision/Recall после каждого уточнения: рост точности и сохранение полноты говорит об эффективном уточнении.
- **Task Completion (успешность задачи):** комплексная метрика, показывающая, насколько система в целом решила поставленную задачу. Это соответствует понятию «Task Completion» или «goal assigasy» (точность выполнения цели). Если цель – предоставить полный и релевантный список источников и обоснование, то Task Completion отражает степень удовлетворения этого требования. Например, можно дать задачу системе с известным решением и проверить, смогла ли она найти основные источники.
- **User Satisfaction (удовлетворённость пользователя):** оценивается опросами или экспертной проверкой результатов. Полезность списка источников и логики рассуждений можно проверять вручную или с помощью профессиональных оценщиков (например, попросить эксперта по теме оценить релевантность и достаточность найденного).
- **Tool-use correctness (правильность работы агентов):** для каждого агента можно проверять технические аспекты. Например, у поисковых агентов – процент корректно используемых API и отсутствие ошибок (согласно метрике «Tool Correctness»), у аналитического – полноту обработки текста (метрики сжатия текста, такие как ROUGE, BLEU, или оценка качества резюме экспертами), у агента-планировщика – адекватность созданного плана (сравнивая с экспертным планом).

- **Время отклика и эффективность:** время выполнения каждого этапа и использования вычислительных ресурсов также важно. Это косвенно влияет на качество (интерактивность, стоимость). Метрика «Task Completion» включает в себя эффективность работы агентов.

Таким образом, система оценивается и количественно (точность/полнота поиска, метрики ранжирования и суммаризации) и качественно (задача выполнена/нет, отзыв пользователя). Эффективность каждого агента можно измерять отдельно (например, precision поискового агента, качество плана планировщика) и в совокупности – по общей полезности результата для пользователя.

## Описание исследовательского процесса (проблемы и решения)

При проектировании системы обнаружено несколько ключевых проблем:

- **Критерии останова для итеративного уточнения:** без чётких критериев цикл «поиск– анализ– уточнение» может заикнуться или обрабатывать несущественные детали. Одним из решений является введение ограничений: например, ограничить число итераций (глубину цепочки уточнений) или остановиться, если за итерацию не найдены новые релевантные источники. В литературе для схожих задач устанавливают глубину цепочки (например, пять итераций) и останавливаются, когда новые запросы не приносят результатов.
- **Баланс точности и полноты:** при уточнении запросов стремление повысить точность (убрать нерелевантные термины) может снизить полноту (упустить редкие релевантные статьи). В идеале уточнение должно повышать точность без потери полноты. Задача – подобрать такие переформулировки. При наличии дополнительных ресурсов можно было бы использовать больший корпус обучающих примеров уточнений (например, из практики библиотечных специалистов) для обучения модели пересчёта важности терминов.
- **Верификация цепочки рассуждений:** проверка корректности логических связей между выводами агента–аналитика может быть сложной. Для этого желательно иметь экспертную аннотацию или знатоков предметной области. При дополнительных ресурсах можно подключить модуль верификации: LLM–эксперт, который проверял бы шаги рассуждения на непротиворечивость или истинен в контексте имеющихся источников.
- **Разнообразие источников и форматов:** агентов нужно оснастить возможностью обрабатывать и интегрировать данные из разных типов (текстовые статьи, базы данных, графы знаний). Это усложняет дизайн поисковых агентов и аналитического агента. Дополнительные ресурсы (например, доступ к профессиональным API научных баз или готовым эмбедингам) улучшили бы охват и качество поиска.
- **Скалируемость и ресурсные ограничения:** поиск в больших базах и анализ множества документов требуют значительных вычислительных мощностей. Если бы были дополнительные ресурсы, можно было бы распределить задачу по кластерам или внедрить параллелизм (например, каждый поисковый агент – отдельный процесс), а также расширить оперативную память для кэширования результатов.

Для преодоления этих проблем можно предложить следующие улучшения при наличии ресурсов:

- **Развитие баз знаний и семантических моделей:** создание онтологии или использования существующих (например, DBpedia, WikiData) помогло бы планировщику лучше разбивать тему, а уточнению – находить релевантные синонимы. Специализированные языковые модели (fine-tuned LLM) на научных текстах повысили бы качество суммаризации и рассуждений.
- **Механизмы обучения:** с дополнительными данными можно обучить агента-координатора на примерах успешных поисковых стратегий, а агента-анализа – на примерах правильно составленных цепочек рассуждений, что повысило бы точность их работы.
- **Интерактивная обратная связь:** развернуть систему так, чтобы пользователь мог корректировать план или оценки промежуточных результатов, превращая поиск в интерактивный процесс. Это потребовало бы дополнительных интерфейсных средств и, возможно, присутствия «агента-посредника» для коммуникации с человеком.

Таким образом, дизайн мультиагентной системы поиска информации требует тщательного выбора ролей агентов и чёткого определения критериев работы. Решения этой задачи строятся на сочетании существующих практик (модульность и специализация агентов) и собственных эвристик (правила остановки, методы оценки). При наличии дополнительных ресурсов можно усилить каждый этап поискового цикла за счёт обучения, расширения базы знаний и привлечения вычислительных мощностей, что улучшит полноту и точность итоговых результатов.

**Источники и методы:** при описании архитектуры и оценки опирались на исследования и обзоры в области мультиагентных систем и информационного поиска. В частности, адаптированы подходы к распределению ролей агентов и метрикам качества, использующиеся в современных системах AI.